

Sistem de clasificare a tipului de barbă folosind rețele neuronale convoluționale

Delcea Iacob

Mihăilă Adelin

Iordan Alexandru

Rezumat

Această lucrare prezintă dezvoltarea unui sistem de clasificare automată a tipului de păr facial din imagini. Sistemul utilizează imagini faciale provenite din baza de date CelebA și dintr-un set de imagini achiziționat manual în laborator. Clasificarea este realizată folosind o rețea neuronală convoluțională ResNet18 pre-antrenată, adaptată pentru patru clase: *Full Beard*, *Goatee*, *Mustache* și *No Facial Hair*.

Lucrarea include etapele de achiziție a datelor, preprocesare, împărțire în seturi de antrenare, validare și testare, antrenare, evaluare și analiză a rezultatelor. Au fost analizate mai multe configurații experimentale, obținute prin combinarea modurilor de dataset cu modurile de crop. Astfel, au fost testate imaginile din CelebA, imaginile achiziționate manual și setul combinat, fiecare în variantele fără crop, crop pe față întreagă și crop pe partea inferioară a feței.

Rezultatele evidențiază importanța calității etichetelor, a evitării data leakage-ului și a alegerii corecte a metodei de preprocesare. De asemenea, analiza matricei de confuzie arată că cele mai dificile cazuri apar între clasele vizual apropiate, precum *Goatee* și *Full Beard*, respectiv *Mustache* și *No Facial Hair*.

Cuprins

1	Introducere	4
2	Obiectivele proiectului	5
3	Descrierea dataset-ului	6
3.0.1	Structura etichetelor	7
3.0.2	Maparea claselor	7
4	Achiziția datelor	8
4.0.1	Subject Distribution	10
4.0.2	Scenarii de captură	10
4.0.3	Ground Truth	11
4.0.4	Data check methodology	11
4.0.5	Database description	11
4.0.6	Output	12
5	Pregătirea datelor	13
5.0.1	Moduri de utilizare a dataset-ului	14
5.0.2	Moduri de crop	14
5.0.3	Combinații experimentale	15
5.0.4	Împărțirea datelor	15
5.0.5	Distribuția claselor	16
6	Preprocesarea imaginilor	17
7	Data augmentation	18
8	Modelul utilizat	19
9	Antrenarea modelului	21
10	Rezultate experimentale	22
10.0.1	Rezultate agregate	22

10.0.2	Rezultate pentru CelebA	22
10.0.3	Rezultate pentru Students	23
10.0.4	Rezultate pentru Both	23
10.0.5	Comparație pe crop mode	23
10.0.6	Comparație pe dataset mode	24
10.0.7	Evoluția antrenării	24
11	Analiza erorilor	25
12	Probleme întâlnite	29
13	Concluzii	30
14	Direcții viitoare	31

Capitolul 1

Introducere

Clasificarea automată a imaginilor reprezintă una dintre cele mai utilizate aplicații ale inteligenței artificiale și ale vederii computerizate. În cadrul acestui proiect a fost dezvoltat un sistem capabil să identifice tipul de păr facial prezent într-o imagine a feței unei persoane.

Problema abordată este una de clasificare multi-clasă, în care fiecare imagine aparține unei singure clase. Cele patru clase definite în proiect sunt prezentate în Tabelul 1.1.

Tabela 1.1: Clasele utilizate în proiect

Index	Clasă	Descriere
0	Full_Beard	Barbă completă, cu păr facial vizibil pe obraji, maxilar și bărbie.
1	Goatee	Păr facial concentrat în zona bărbiei, eventual împreună cu mustață.
2	Mustache	Mustață vizibilă, fără barbă semnificativă pe bărbie sau obraji.
3	No_Facial_Hair	Lipsa părului facial vizibil sau existența unei umbre foarte fine.

Scopul proiectului este de a evalua dacă o rețea neuronală convoluțională pre-antrenată poate fi adaptată eficient pentru identificarea tipului de păr facial, folosind atât date existente, cât și date achiziționate manual.

Capitolul 2

Obiectivele proiectului

Obiectivele principale ale proiectului sunt:

- construirea unui dataset pentru clasificarea tipului de barbă;
- utilizarea bazei de date CelebA și a unui set de date achiziționat manual;
- definirea unui proces de preprocesare și pregătire a datelor;
- antrenarea unui model ResNet18 folosind transfer learning;
- compararea mai multor moduri de pregătire a imaginilor;
- evaluarea performanței prin acuratețe, matrice de confuzie și raport de clasificare.

Tabela 2.1: Obiective și metode de realizare

Obiectiv	Metodă de realizare
Clasificare multi-clasă	Definirea a patru clase exclusive.
Utilizarea unui dataset existent	Selectarea atributelor relevante din CelebA.
Achiziție proprie de date	Fotografierea subiecților în condiții controlate.
Reducerea overfitting-ului	Dropout, weight decay, data augmentation și fine-tuning parțial.
Analiza performanței	Matrice de confuzie, acuratețe, precision, recall și F1-score.

Capitolul 3

Descrierea dataset-ului

Pentru realizarea proiectului au fost utilizate două surse de date:

1. **CelebA** – bază de date publică ce conține imagini faciale și attribute asociate;
2. **Students dataset** – set de imagini achiziționat manual în laborator.

CelebA conține imagini de dimensiune 178×218 pixeli, în format JPG. Setul de imagini achiziționat manual a fost prelucrat pentru a respecta aceeași formă și același format.

Tabela 3.1: Sursele de date utilizate

Sursă	Format	Rezoluție	Observații
CelebA	JPG	178x218	Imagini deja centrate pe față.
Students	JPG	178x218	Imagini achiziționate manual și redimensionate.
Both	JPG	178x218	Combinarea celor două seturi pentru experimente.

3.0.1 Structura etichetelor

Inițial, datele au fost stocate într-un fișier Excel, unde prima coloană conține numele imaginii, iar a doua coloană conține clasa numerică asociată. Ulterior, imaginile au fost împărțite automat în directoare corespunzătoare claselor.

Tabela 3.2: Exemplu de structură a fișierului de etichete

image_name	class
000001.jpg	3
000002.jpg	0
000003.jpg	1
000004.jpg	2

3.0.2 Maparea claselor

Deoarece `ImageFolder` ordonează clasele alfabetic, maparea claselor a fost ajustată pentru a evita diferențe între etichetele din fișierele Excel și etichetele utilizate intern de PyTorch.

Tabela 3.3: Maparea finală a claselor

Index	Clasă	Ordine ImageFolder
0	Full_Beard	1
1	Goatee	2
2	Mustache	3
3	No_Facial_Hair	4

Capitolul 4

Achiziția datelor

Pentru partea experimentală, a fost realizată și o achiziție proprie de imagini. Scopul acesteia a fost de a testa modelul pe imagini obținute într-un mediu controlat, diferit de baza de date CelebA. În total au fost fotografiați 22 de studenți, iar imaginile rezultate au fost folosite împreună cu imaginile din CelebA pentru antrenarea, validarea și testarea sistemului.

Tabela 4.1: Acquisition Requirements

Câmp	Valoare
Start date	02/04/2026
End date	02/04/2026
Environment	In the lab
Equipment	DSLR, tripod, speedlight (on camera flash)
Allocated budget	20
Estimated total costs	15
Client	Concept Team
Data verify time	13.05.2026; 21.05.2026
Split time	23.05.2026
Review split time	25.05.2026
Train data location	CelebA dataset and local laboratory acquisition
Validation data location	CelebA dataset and local laboratory acquisition
Test data location	CelebA dataset and local laboratory acquisition

Tabela 4.2: Cerințe pentru achiziția datelor

Categorie	Descriere
Mediu	Laborator, fundal neutru, lumină ambientală suficientă.
Echipament	DSLR, trepied și speedlight.
Subiecți	22 subiecți, cu distribuție echilibrată pe clase unde este posibil.
Operatori	3 operatori pentru captură și verificare.
Format imagine	JPG, redimensionare la 178x218 pixeli.
Clase	Full_Beard, Goatee, Mustache, No_Facial_Hair.

Tabela 4.3: Resurse umane implicate în achiziție

Resursă	Descriere
Subjects	22 students photographed.
Operators	3 operators.
Annotators	Manual annotation performed for facial hair class labels.
Developer	Dataset preparation, training and evaluation scripts.

Tabela 4.4: Echipamente utilizate pentru achiziția imaginilor

Echipament	Specificații
DSLR – Nikon D850	45.7MP Backside Illuminated Full-Frame CMOS sensor, dynamic range 14EV (@ ISO 64), ISO 64–25600, 35.9 × 23.9 mm, aspect ratio 3:2.
Tripod – K&F Concept	1.6m collapsible carbon fibre tripod, allows landscape and portrait orientations while maintaining camera stability.
Flash – Nikon SB-28	Tiltable and zoomable head, power adjustment from 1/64 to 1/1 with 1/3rd stop increments.

4.0.1 Subject Distribution

Distribuția subiecților a fost stabilită pentru a introduce variație în setul de date, în limita disponibilității persoanelor fotografiate.

Tabela 4.5: Distribuția subiecților

Criteriu	Descriere
Gender	50% male, 50% female, unde este posibil.
Race	Mainly caucasian, other races if possible.
Age	Evenly distributed, în limita grupului de studenți disponibil.
Face covering	Subjects will not wear any face covering that may obstruct the lower part of their face.

4.0.2 Scenarii de captură

Pentru fiecare subiect, imaginile au fost realizate din mai multe unghiuri, pentru a introduce variație în setul de date.

Tabela 4.6: Scenarii de captură

Nr.	Scenariu	Descriere
1	Frontal	Subiectul privește direct spre cameră.
2	Yaw -45	rotație spre stânga.
3	Yaw +45	rotație spre dreapta.
4	Frontal + flash	Subiectul privește direct spre camera. Iluminare controlată printr-un flash montat pe DSLR.
5	Yaw -45 + flash	rotație spre stânga. Iluminare controlată printr-un flash montat pe DSLR.
6	Yaw +45 + flash	rotație spre dreapta. Iluminare controlată printr-un flash montat pe DSLR.

Aceste trei scenarii sunt suficiente pentru a acoperi majoritatea cazurilor detectabile de păr facial în imaginile folosite.

Tabela 4.7: Factori externi considerați în achiziție

Factor	Descriere
Lighting variations	Natural/artificial lighting variations.
Pose variations	Slight pose variations between subjects.
Background variations	Limited background variations, using a neutral background where possible.

4.0.3 Ground Truth

Fiecare imagine este etichetată cu una dintre cele patru clase finale utilizate în aplicație.

Tabela 4.8: Ground Truth – clasele finale

Index	Clasă
0	Full_Beard
1	Goatee
2	Mustache
3	No_Facial_Hair

4.0.4 Data check methodology

Tabela 4.9: Metodologia de verificare a datelor

Verificare	Descriere
Manual verification of labels	Labels are manually checked for consistency.
Removal of unclear images	Images with occluded or unclear faces are removed.
Consistency check	Class labels are checked to avoid contradictions between similar classes.

4.0.5 Database description

Tabela 4.10: Descrierea bazei de date

Caracteristică	Valoare
Image type	RGB face images.
Resolution	178x218 pixels.
Region of interest	Facial hair region.
Format	.jpg.
Dataset modes	CelebA, Students, Both.
Crop modes	None, Face, Lower Face.
Labels	Image name and class label.

4.0.6 Output

Tabela 4.11: Output-ul procesului de achiziție

Output	Descriere
Annotated image dataset	Set de imagini etichetate pentru clasificarea tipului de barbă.
Class labels	Etichete pentru cele patru clase de păr facial.
Metadata	Numele imaginii și clasa asociată.

Capitolul 5

Pregătirea datelor

Datele brute sunt transformate într-o structură compatibilă cu modulul `ImageFolder` din PyTorch. Această structură presupune existența unui director pentru fiecare clasă.

```
data/  
  train/  
    Full_Beard/  
    Goatee/  
    Mustache/  
    No_Facial_Hair/  
  val/  
    Full_Beard/  
    Goatee/  
    Mustache/  
    No_Facial_Hair/  
  test/  
    Full_Beard/  
    Goatee/  
    Mustache/  
    No_Facial_Hair/
```

5.0.1 Moduri de utilizare a dataset-ului

Pentru experimente, aplicația permite alegerea sursei de date.

Tabela 5.1: Moduri de utilizare a dataset-ului

Mod	Valoare	Descriere
1	CelebA	Se utilizează doar imaginile din baza de date CelebA.
2	Students	Se utilizează doar imaginile achiziționate manual.
3	Both	Se combină imaginile CelebA cu imaginile achiziționate manual.

5.0.2 Moduri de crop

Pentru fiecare mod de dataset au fost testate trei moduri de crop.

Tabela 5.2: Moduri de crop utilizate

Mod crop	Descriere
None	Imaginea este utilizată fără decupare.
Face	Se detectează fața și se păstrează zona facială completă.
Lower Face	Se păstrează zona inferioară a feței, relevantă pentru mustață, bărbie și maxilar.

5.0.3 Combinații experimentale

Prin combinarea celor trei moduri de dataset cu cele trei moduri de crop au rezultat nouă configurații experimentale.

Tabela 5.3: Toate combinațiile experimentale testate

Nr.	Dataset mode	Crop mode	Descriere
1	CelebA	None	Imagini CelebA originale, fără crop suplimentar.
2	CelebA	Face	Imagini CelebA cu crop pe fața întreagă.
3	CelebA	Lower Face	Imagini CelebA cu crop pe partea inferioară a feței.
4	Students	None	Imagini achiziționate manual, fără crop suplimentar.
5	Students	Face	Imagini achiziționate manual cu crop pe față.
6	Students	Lower Face	Imagini achiziționate manual cu crop pe zona inferioară.
7	Both	None	CelebA și Students combinate, fără crop.
8	Both	Face	CelebA și Students combinate, cu crop pe față.
9	Both	Lower Face	CelebA și Students combinate, cu crop pe zona inferioară.

5.0.4 Împărțirea datelor

Datele au fost împărțite în trei subseturi: antrenare, validare și testare.

Tabela 5.4: Proporțiile utilizate pentru împărțirea datelor

Subset	Procent	Rol
Train	70%	Antrenarea modelului.
Validation	15%	Alegerea celei mai bune configurații.
Test	15%	Evaluarea finală.

Tabela 5.5: Distribuția imaginilor pe subseturi pentru fiecare configurație de dataset

Dataset mode	Train	Validation	Test
CelebA	1936	415	416
Students	118	27	26
Both	2054	442	442

5.0.5 Distribuția claselor

Tabelele următoare prezintă exemple de distribuție pe clase. Valorile sunt orientative și pot fi înlocuite cu rezultatele generate de aplicație.

Tabela 5.6: Distribuția claselor pentru CelebA

Clasă	Train	Validation	Test
Full_Beard	479	102	103
Goatee	492	106	106
Mustache	473	102	101
No_Facial_Hair	492	105	106

Tabela 5.7: Distribuția claselor pentru Students

Clasă	Train	Validation	Test
Full_Beard	22	6	5
Goatee	14	6	4
Mustache	21	5	4
No_Facial_Hair	61	10	13

Tabela 5.8: Distribuția claselor pentru Both

Clasă	Train	Validation	Test
Full_Beard	501	108	108
Goatee	506	112	110
Mustache	494	107	105
No_Facial_Hair	553	115	119

Capitolul 6

Preprocesarea imaginilor

În etapa de preprocesare au fost analizate trei variante: imagine originală, crop pe față întreagă și crop pe partea inferioară a feței.

Tabela 6.1: Avantaje și dezavantaje ale metodelor de crop

Metodă	Avantaje	Dezavantaje
None	Simplu, fără risc de tăiere greșită.	Modelul poate învăța fundalul sau alte elemente irelevante.
Face	Reduce zgomotul de fundal și păstrează context facial.	Depinde de calitatea detectorului de fețe.
Lower Face	Se concentrează pe zona bărbii și mustății.	Poate elimina context util dacă decuparea este greșită.

Tabela 6.2: Strategia de fallback pentru crop

Dataset	Caz	Acțiune
CelebA	Față detectată	Se aplică crop pe baza detectorului.
CelebA	Față nedetectată	Se aplică un crop fix, deoarece imaginile sunt centrate.
Students	Față detectată	Se aplică crop pe baza detectorului.
Students	Față nedetectată	Imaginea este verificată manual sau se aplică fallback fix.

Capitolul 7

Data augmentation

Pentru reducerea overfitting-ului a fost utilizată augmentarea imaginilor în timpul antrenării. Augmentarea este aplicată doar pe setul de antrenare, nu și pe seturile de validare și testare.

Tabela 7.1: Transformări aplicate imaginilor

Transformare	Rol	Aplicare
Resize	Redimensionează imaginea la dimensiunea de intrare.	Train / Val / Test
RandomHorizontalFlip	Simulează variații de orientare.	Train
RandomRotation	Simulează mici rotații ale capului.	Train
ColorJitter	Modifică luminozitatea și contrastul.	Train
RandomAffine	Simulează mici translații și scalări.	Train
Normalize	Normalizează imaginea folosind valorile ImageNet.	Train / Val / Test

```
1 train_transform = transforms.Compose([
2     transforms.Resize(IMAGE_SIZE),
3     transforms.RandomHorizontalFlip(p=0.5),
4     transforms.RandomRotation(15),
5     transforms.ColorJitter(
6         brightness=0.3,
7         contrast=0.3,
8         saturation=0.2),
9     transforms.RandomAffine(
10        degrees=0,
11        translate=(0.05, 0.05),
12        scale=(0.9, 1.1)), transforms.ToTensor(),
13    transforms.Normalize(mean=IMAGENET_MEAN, std=IMAGENET_STD),
14    ])
```

Capitolul 8

Modelul utilizat

Modelul ales este ResNet18, o rețea neuronală convoluțională utilizată frecvent în probleme de clasificare a imaginilor. În proiect s-a folosit transfer learning, prin încărcarea greutăților pre-antrenate pe ImageNet.

Tabela 8.1: Modificarea stratului final

Model	Intrări FC	Ieșiri FC
ResNet18 original	512	1000
ResNet18 adaptat	512	4

```
1 def get_model():
2     model = models.resnet18(weights=models.ResNet18_Weights.DEFAULT
3         )
4
5     model.fc = nn.Sequential(
6         nn.Dropout(0.5),
7         nn.Linear(model.fc.in_features, NUM_CLASSES),
8     )
9
10    for name, param in model.named_parameters():
11        param.requires_grad = name.startswith("layer4") or name.
12            startswith("fc")
13
14    return model
```

Tabela 8.2: Strategii de fine-tuning testate

Strategie	Train Acc	Val Acc	Observație
FC antrenabile	0.4282	0.4458	Underfitting.
Layer4.1 + FC antrenabile	0.7996	0.5639	Usor Overfitting.
Layer4 + FC antrenabile	0.9298	0.6169	Overfitting puternic.
Layer4 + FC + crop	0.9029	0.7046	Exemplu de rezultat îmbunătățit.

Capitolul 9

Antrenarea modelului

Modelul a fost antrenat folosind funcția de pierdere CrossEntropyLoss și optimizatorul AdamW. Pentru reducerea overfitting-ului au fost utilizate dropout, weight decay și label smoothing.

Tabela 9.1: Hiperparametri utilizați

Hiperparametru	Valoare exemplu
Batch size	32
Epochs	20
Learning rate	1×10^{-4}
Optimizer	AdamW
Weight decay	1×10^{-3}
Dropout	0.5
Label smoothing	0.1
Scheduler	ReduceLROnPlateau

Tabela 9.2: Rolul principalilor hiperparametri

Hiperparametru	Rol
Learning rate	Controlează mărimea pașilor de actualizare a greutateților.
Batch size	Stabilește numărul de imagini procesate simultan.
Weight decay	Penalizează greutatețile mari și reduce overfitting-ul.
Dropout	Dezactivează aleator o parte din neuroni în timpul antrenării.
Label smoothing	Reduce încrederea excesivă a modelului în predicții.
Scheduler	Scade learning rate-ul când performanța pe validare stagnează.

Capitolul 10

Rezultate experimentale

În această secțiune sunt prezentate rezultate exemplu pentru toate combinațiile dintre modurile de dataset și modurile de crop. Valorile trebuie înlocuite cu rezultatele finale obținute în urma rulărilor.

10.0.1 Rezultate agregate

Tabela 10.1: Rezultate pentru toate combinațiile dataset mode - crop mode

Dataset	Crop	Train Acc	Val Acc	Test Acc	Val Loss
CelebA	None	0.5971	0.6241	0.6010	1.0344
CelebA	Face	0.6947	0.6747	0.6274	0.9990
CelebA	Lower Face	0.7221	0.6506	0.6538	1.0086
Students	None	0.9576	0.5926	0.8846	2.0815
Students	Face	0.7881	0.5185	0.8077	1.8023
Students	Lower Face	0.9407	0.5926	0.8846	1.4556
Both	None	0.9474	0.6176	0.6335	1.2510
Both	Face	0.7804	0.6878	0.6719	0.9704
Both	Lower Face	0.7692	0.6742	0.6448	1.0058

10.0.2 Rezultate pentru CelebA

Tabela 10.2: Rezultate detaliate pentru CelebA

Crop	Train Loss	Train Acc	Val Loss	Val Acc	Test Acc
None	1.0392	0.5971	1.0344	0.6241	0.6010
Face	0.9142	0.6947	0.9990	0.6747	0.6274
Lower Face	0.8682	0.7221	1.0086	0.6506	0.6538

10.0.3 Rezultate pentru Students

Tabela 10.3: Rezultate detaliate pentru Students

Crop	Train Loss	Train Acc	Val Loss	Val Acc	Test Acc
None	0.5567	0.9576	2.0815	0.5926	0.8846
Face	0.8565	0.7881	1.8023	0.5185	0.8077
Lower Face	0.5730	0.9407	1.4556	0.5926	0.8846

10.0.4 Rezultate pentru Both

Tabela 10.4: Rezultate detaliate pentru Both

Crop	Train Loss	Train Acc	Val Loss	Val Acc	Test Acc
None	0.5145	0.9474	1.2510	0.6176	0.6335
Face	0.7840	0.7804	0.9704	0.6878	0.6719
Lower Face	0.7881	0.7692	1.0058	0.6742	0.6448

10.0.5 Comparație pe crop mode

Tabela 10.5: Comparație între modurile de crop, mediat pe toate dataset-urile

Crop mode	Val Acc mediu	Test Acc mediu	Observație
None	0.6114	0.7064	Performanță variabilă; în unele cazuri modelul poate învăța și elemente nerelevante din imagine.
Face	0.6270	0.7023	Performanță mai stabilă prin eliminarea unei părți din fundal.
Lower Face	0.6391	0.7277	Cea mai bună medie, deoarece zona inferioară a feței este cea mai relevantă pentru clasificarea bărbii.

10.0.6 Comparație pe dataset mode

Tabela 10.6: Comparație între modurile de dataset, mediat pe toate crop-urile

Dataset mode	Val Acc mediu	Test Acc mediu	Observație
CelebA	0.6498	0.6274	Set mare, cu rezultate stabile, dar cu posibile etichete ambigue.
Students	0.5679	0.8590	Set mic; diferența mare între validare și test indică sensibilitate la împărțirea manuală.
Both	0.6599	0.6501	Cea mai bună medie pe validare, combinând diversitatea CelebA cu imaginile achiziționate manual.

10.0.7 Evoluția antrenării

Tabela 10.7: Evoluția antrenării pentru configurația Both + Lower Face

Epoch	LR	Train Loss	Train Acc	Val Acc
1	0.000100	1.2899	0.4606	0.5543
5	0.000100	0.9275	0.6889	0.6357
10	0.000100	0.7667	0.7838	0.6629
15	0.000100	0.6533	0.8588	0.6561
20	0.000050	0.5908	0.8924	0.6312

Capitolul 11

Analiza erorilor

Matricea de confuzie este utilizată pentru a observa clasele care sunt confundate între ele. Analiza erorilor este importantă deoarece acuratețea totală nu arată exact între ce clase apar cele mai multe confuzii.

În cazul acestui proiect, principalele dificultăți apar între clase vizual apropiate. Clasa *Goatee* poate fi confundată cu *Full Beard*, deoarece în unele imagini părul facial din zona bărbiei se extinde și spre maxilar. De asemenea, clasa *Mustache* poate fi confundată cu *No Facial Hair* atunci când mustața este subtilă, are contrast redus sau este afectată de iluminare.

Trebuie menționat că setul de date achiziționat manual este redus ca dimensiune, iar unele persoane pot apărea în mai multe subseturi. Acest lucru poate influența rezultatele, în special pentru configurațiile care folosesc dataset-ul *Students*.

Tabela 11.1: Matrice de confuzie pentru *Students + None*

True / Pred	Full Beard	Goatee	Mustache	No Facial Hair
Full Beard	5	0	0	0
Goatee	2	2	0	0
Mustache	0	0	3	1
No Facial Hair	0	0	0	13

Pentru configurația *Students + None*, modelul obține rezultate bune pe setul de test, cu o acuratețe de 0.8846. Totuși, se observă că două imagini din clasa *Goatee* sunt clasificate ca *Full Beard*, ceea ce confirmă dificultatea de separare între aceste două clase. De asemenea, o imagine din clasa *Mustache* este clasificată ca *No Facial Hair*.

Tabela 11.2: Raport de clasificare pentru Students + None

Clasă	Precision	Recall	F1-score	Support
Full_Beard	0.71	1.00	0.83	5
Goatee	1.00	0.50	0.67	4
Mustache	1.00	0.75	0.86	4
No_Facial_Hair	0.93	1.00	0.96	13
Accuracy		0.88		26
Macro avg	0.91	0.81	0.83	26
Weighted avg	0.91	0.88	0.88	26

Tabela 11.3: Matrice de confuzie pentru Students + Face

True / Pred	Full Beard	Goatee	Mustache	No Facial Hair
Full Beard	4	0	0	1
Goatee	1	3	0	0
Mustache	0	0	2	2
No Facial Hair	1	0	0	12

În configurația *Students + Face*, acuratețea pe test este 0.8077. Comparativ cu varianta fără crop, modelul clasifică mai bine clasa *Goatee*, dar apar mai multe confuzii între *Mustache* și *No Facial Hair*. Acest lucru sugerează că decuparea feței poate elimina fundalul, dar nu rezolvă complet cazurile în care mustața este subtilă.

Tabela 11.4: Matrice de confuzie pentru Students + Lower Face

True / Pred	Full Beard	Goatee	Mustache	No Facial Hair
Full Beard	5	0	0	0
Goatee	2	2	0	0
Mustache	0	0	3	1
No Facial Hair	0	0	0	13

Configurația *Students + Lower Face* are aceeași acuratețe pe test ca *Students + None*, respectiv 0.8846. Acest lucru indică faptul că zona inferioară a feței conține informația principală necesară pentru clasificarea tipului de păr facial. Totuși, pentru dataset-ul *Students*, dimensiunea redusă a setului de test face ca scorurile să fie sensibile la câteva imagini.

Tabela 11.5: Matrice de confuzie pentru Both + Lower Face

True / Pred	Full Beard	Goatee	Mustache	No Facial Hair
Full Beard	54	34	15	5
Goatee	21	65	23	1
Mustache	12	22	66	5
No Facial Hair	5	6	8	100

Pentru configurația *Both + Lower Face*, modelul obține o acuratețe de 0.6448 pe setul de test. Se observă că performanța este mai echilibrată între clase față de unele configurații pe Students, dar apar în continuare confuzii importante între *Full Beard*, *Goatee* și *Mustache*. Clasa *No Facial Hair* este clasificată cel mai bine, având 100 predicții corecte din 119 imagini.

Tabela 11.6: Raport de clasificare pentru Both + Lower Face

Clasă	Precision	Recall	F1-score	Support
Full_Beard	0.59	0.50	0.54	108
Goatee	0.51	0.59	0.55	110
Mustache	0.59	0.63	0.61	105
No_Facial_Hair	0.90	0.84	0.87	119
Accuracy		0.64		442
Macro avg	0.65	0.64	0.64	442
Weighted avg	0.65	0.64	0.65	442

Tabela 11.7: Clase confundate frecvent

Confuzie	Cauză posibilă	Soluție propusă
Goatee → Full_Beard	Părul facial din zona bărbiei se poate extinde spre maxilar, iar unele exemple sunt borderline.	Definirea mai strictă a clasei Goatee și eliminarea imaginilor ambigue.
Full_Beard → Goatee	Barba scurtă sau rară poate părea concentrată în zona bărbiei.	Creșterea numărului de exemple clare pentru Full_Beard.
Mustache → No_Facial_Hair	Mustață subtilă, iluminare slabă sau contrast redus în zona buzei superioare.	Folosirea crop-ului pe zona inferioară și imagini cu rezoluție mai bună.
No_Facial_Hair → Mustache	Umbre, zgomot vizual sau contrast neuniform în zona buzei superioare.	Control mai bun al iluminării și verificare manuală a etichetelor.
Mustache → Goatee	Mustața poate apărea împreună cu umbre în zona bărbiei.	Etichetare mai clară și exemple suplimentare pentru Mustache.

În concluzie, analiza erorilor arată că problema nu este distribuită uniform între toate clasele. Cele mai bune rezultate apar pentru clasa *No Facial Hair*, deoarece aceasta este mai ușor de separat vizual. Cele mai dificile clase sunt *Goatee* și *Mustache*, deoarece acestea depind de detalii locale și pot fi confundate cu clase apropiate. Pentru îmbunătățiri ulterioare, este necesară creșterea numărului de subiecți, curățarea etichetelor ambigue și folosirea unui crop mai precis pe zona relevantă a feței.

Capitolul 12

Probleme întâlnite

Pe parcursul proiectului au fost întâlnite mai multe probleme, prezentate în Tabelul 12.1.

Tabela 12.1: Probleme întâlnite și soluții

Problemă	Cauză posibilă	Soluție aplicată
Overfitting	Dataset mic sau clase ambigue.	Dropout, weight decay, augmentare.
Underfitting	Prea multe straturi înghețate.	Fine-tuning parțial pe layer4.1 și FC.
Data leakage	Aceeași persoană în train și validation.	Split pe subiecți, nu pe imagini.
Label noise	Etichete ambigue în CelebA.	Verificare manuală și curățare.
Mismatch clase	Ordinea alfabetică ImageFolder diferită de Excel.	Remaparea claselor în ordine alfabetică.
Detector fețe eșuat	Imagini mici sau detector prea slab.	Crop fix / fallback.

Tabela 12.2: Observații asupra calității datelor

Aspect	Impact	Măsură de control
Etichete ambigue	Scor de validare instabil.	Verificare manuală.
Număr redus de subiecți	Generalizare slabă pe persoane noi.	Creșterea numărului de subiecți.
Cazuri borderline	Confuzie între clase apropiate.	Definiții clare pentru clase.
Data leakage	Val accuracy artificial ridicat.	Split pe subiecți.
Fundal variabil	Modelul poate învăța informații irelevante.	Face crop sau lower face crop.

Capitolul 13

Concluzii

În cadrul proiectului a fost dezvoltat un sistem de clasificare a tipului de păr facial folosind ResNet18 și transfer learning. Au fost utilizate două surse de date: CelebA și un dataset achiziționat manual. Rezultatele au evidențiat importanța calității etichetelor, a evitării data leakage-ului și a unei împărțiri corecte a datelor.

Cele mai importante observații sunt:

- modelul poate învăța rapid setul de antrenare, dar generalizarea este dificilă pe subiecți noi;
- clasele *Goatee* și *Full Beard* sunt vizual apropiate și pot fi confundate;
- clasele *Mustache* și *No Facial Hair* pot fi confundate dacă mustața este subtilă;
- crop-ul pe față sau pe zona inferioară a feței poate reduce influența fundalului;
- un dataset de validare curat este esențial pentru evaluarea corectă a modelului;
- combinația *Both + Lower Face* este, teoretic, cea mai promițătoare deoarece combină diversitatea CelebA cu datele controlate achiziționate manual.

Capitolul 14

Direcții viitoare

Pentru îmbunătățirea sistemului, pot fi avute în vedere următoarele direcții:

- creșterea numărului de subiecți pentru fiecare clasă;
- curățarea manuală a etichetelor ambigue;
- testarea mai multor arhitecturi CNN, precum MobileNet sau EfficientNet;
- utilizarea unui detector de landmarks pentru crop mai precis;
- compararea performanței între full image, face crop și lower face crop;
- dezvoltarea unei interfețe pentru predicții pe imagini încărcate de utilizator.

Bibliografie

- [1] Torchvision ResNet18 Documentation.
<https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html>
- [2] CelebFaces Attributes (CelebA) Dataset – Kaggle.
<https://www.kaggle.com/datasets/jessicali9530/celeba-dataset>
- [3] PyTorch Documentation.
<https://pytorch.org/docs/stable/index.html>
- [4] Torchvision Models Documentation.
<https://pytorch.org/vision/stable/models.html>
- [5] OpenCV Documentation.
<https://docs.opencv.org>
- [6] Dlib C++ Library Documentation.
<http://dlib.net>